

Inteligencia Artificial en el Deporte: Optimización de Mapas Autoorganizados mediante Algoritmos Genéticos para la Segmentación de Comportamiento en el Fútbol de Élite

Maximiliano Rivas
Ingeniería Estadística (5to Año)
Universidad de Concepción, Chile

Julio, 2026

Resumen

El análisis moderno del fútbol exige metodologías capaces de agrupar a los jugadores no por su posición nominal en el campo, sino por su comportamiento real y su estilo táctico dinámico. Este artículo detalla la construcción de un ecosistema de aprendizaje automático no supervisado a partir de más de un millón de eventos atómicos de torneos internacionales. Para mapear la complejidad del juego, empleamos los Mapas Autoorganizados de Kohonen (SOM). Sin embargo, configurar estas redes de manera empírica suele romper la lógica geométrica del mapa. Para solucionarlo, implementamos un Algoritmo Genético (AG) que actúa como un selector evolutivo de parámetros. Los resultados demuestran que el modelo guiado por el AG incrementa disminuye en 3,35 % el error de ajuste además de mejorar un 57,84 % la coherencia del mapa (Error Topológico). Este equilibrio evita el sobreajuste y garantiza que los jugadores similares queden agrupados en una geografía lógica, creando una herramienta intuitiva y transparente para el análisis deportivo profesional.

Palabras clave: Machine Learning, Mapas Autoorganizados (SOM), Algoritmos Genéticos, Analítica de Fútbol, StatsBomb, Agrupamiento Táctico.

1. INTRODUCCIÓN Y MOTIVACIÓN TÁCTICA

En el fútbol tradicional, las herramientas de evaluación analítica solían limitarse a contar eventos aislados: cuántos goles metió un delantero, cuántos pases completó un mediocampista o cuántas intercepciones hizo un defensor. Este enfoque presenta dos problemas conceptuales graves:

1. **Ignora el estilo de juego conceptual:** Dos mediocampistas pueden registrar un 90 % de efectividad de pases, pero uno lo hace dando pases horizontales seguros de 5 metros en su propia mitad de la cancha, mientras que el otro arriesga pases profundos “filtrados” entre las líneas defensivas rivales. Sus estadísticas tradicionales se ven idénticas en volumen, pero sus comportamientos tácticos son completamente opuestos.
2. **La rigidez de las posiciones nominales:** Catalogar a un futbolista simplemente como “mediocampista” es insuficiente. En el fútbol moderno existen interiores con llegada, volantes de contención puros, organizadores adelantados y mediocentros laterales.

El objetivo general de este estudio es desarrollar un sistema estadístico que tome las características multidimensionales de los futbolistas y los agrupe (clústerice) de acuerdo a lo que *realmente hacen* en la cancha. Al hacerlo, un cuerpo técnico o un analista de fichajes (*scouting*) puede buscar reemplazos perfectos basándose en el comportamiento dinámico. Si un equipo pierde a un jugador clave, el sistema

no buscará a alguien en su misma posición formal; buscará a un futbolista cuyo perfil de comportamiento en la matriz de juego sea equivalente.

Para lograr esto de forma robusta, combinamos dos ramas de la Inteligencia Artificial: los Mapas Autoorganizados (SOM), encargados de dibujar una geografía visual de los estilos de juego, y los Algoritmos Genéticos (AG), encargados de calibrar de forma óptima las matemáticas del mapa para garantizar su estabilidad y veracidad.

2. PROCESAMIENTO DE DATOS E INGENIERÍA DE VARIABLES ULTRA-DETALLADA

El núcleo analítico de este proyecto radica en la transformación de un origen de datos remoto, masivo y fragmentado en una matriz de diseño limpia y comparable. El flujo de trabajo se divide de forma estricta en cuatro fases estadísticas secuenciales.

2.1 Fase 1: Establecimiento del Universo y Máscaras Lógicas a Nivel de Evento

El análisis se alimenta de la base de datos abierta de *StatsBomb*. Para construir un paradigma que represente el fútbol global contemporáneo y no los sesgos de una sola región o liga, consolidamos los eventos de múltiples competiciones de selecciones absolutas: los Mundiales de la FIFA 2018 y 2022, las Eurocopas 2020 y 2024, la Copa América 2024 y la Copa Africana de Naciones 2023. El volumen crudo inicial asciende a **1.106.277 acciones analíticas individuales**.

En este dataset crudo de eventos, cada fila representa una fracción de segundo en la cancha (un pase, un remate, una falta). Para extraer valor, primero creamos **máscaras lógicas y condicionales booleanas** que etiquetan la naturaleza conceptual de cada acción individual:

- **Pases:** Se identifica si el evento corresponde a un intento de distribución (`type == 'Pass'`). Se cruza con el campo de desenlace (`pass_outcome`) para etiquetar si fue un *pase exitoso* (llegó a destino) o un *filtrado exitoso* (rompió líneas defensivas). Asimismo, se evalúa el estrés táctico mediante la máscara de *pase bajo presión*, que registra si un rival estaba acosando físicamente al jugador durante la acción.
- **Tiros y Goles Esperados (xG):** Se aíslan los remates (`type == 'Shot'`) y los goles reales. Para medir el peligro subyacente de manera científica, se extrae la métrica continua `shot_statsbomb_xg` (Expected Goals). El xG es un modelo probabilístico que asigna a cada tiro un valor entre 0 y 1, indicando qué tan probable es que termine en gol según la distancia, el ángulo, la presión defensiva y la posición del arquero. Si la fila no es un tiro, el xG se imputa automáticamente como 0.
- **Fase Defensiva y Disputas:** Se aíslan las *intercepciones* (cortes de líneas de pase rivales) y las *recuperaciones* (recolección de balones sueltos). Para el juego aéreo, se cruzan los eventos de duelo (`Duel`) filtrando aquellos catalogados explícitamente como aéreos, separando las disputas totales de los *duelos aéreos ganados*.

2.2 Fase 2: Agregación Vectorial por Jugador y Control de Varianza

Una vez etiquetados los más de un millón de eventos, la unidad de análisis cambia por completo. Pasamos de una “matriz de acciones” a una “matriz de jugadores” agrupando por futbolista y equipo (`groupby(['player', 'team'])`). En este paso se calcula el volumen bruto absoluto de cada jugador (goles totales, pases totales, intercepciones totales, etc.).

Sin embargo, incorporar volúmenes brutos directamente en un modelo introduce un sesgo de exposición devastador: un jugador que disputó 7 partidos completos registrará números mucho más altos que un jugador de igual calidad que solo disputó 3 partidos debido a la eliminación temprana de su selección. Para corregir esto, primero calculamos el tiempo neto de exposición en cancha de cada futbolista sumando los minutos máximos registrados en cada partido.

Aquí implementamos un paso estadístico innegociable: el **Filtro de Representatividad Estricto**. Descartamos a cualquier futbolista que sume menos de **270 minutos de juego netos** (el equivalente a 3 partidos completos). En estadística, las muestras pequeñas introducen una volatilidad extrema (alta varianza). Si un jugador entra a la cancha solo 10 minutos, ejecuta un único tiro y anota un gol, sus estadísticas proyectadas dirían que tiene un 100 % de efectividad y anota 9 goles por partido. Este filtro limpia el ruido, eliminando rachas de fortuna momentáneas y asegurando que la base de datos decante en **1.288 jugadores estables** con hábitos tácticos consistentes.

2.3 Fase 3: Estandarización de Tasas P90 y Razones Matemáticas de Eficiencia

Con la muestra filtrada, procedemos a construir las variables relativas finales que alimentarán a los algoritmos de Machine Learning. Transformamos los volúmenes absolutos en tasas estandarizadas por cada 90 minutos de juego (Métricas P90) y en razones de eficiencia interna, garantizando la equidad paramétrica. Seleccionamos **10 variables directrices**:

1. **xG P90 (Volumen de Peligro)**: Peligro estadístico acumulado por el jugador proyectado a un partido completo. Mide su capacidad para posicionarse en zonas de remate de alto valor.
2. **xG por Tiro (Calidad de la Decisión)**: Se calcula dividiendo el xG total entre los tiros totales intentados. Evalúa la racionalidad del jugador: un valor alto indica que solo remata cuando la probabilidad de gol es óptima; un valor bajo indica que dispara con egoísmo desde distancias lejanas o ángulos imposibles.
3. **% Pases Bajo Presión (Estrés Táctico)**: Razón entre pases ejecutados bajo acoso rival e influencia global. Mide qué porcentaje del juego del futbolista ocurre en escenarios de asedio posicional.
4. **Asistencias a Tiro P90 (Creatividad Operacional)**: Frecuencia con la que el jugador entrega pases que terminan directamente en un remate de un compañero (pases clave o *key passes*).
5. **% Pases Exitosos (Seguridad en Distribución)**: Porcentaje de efectividad general en la entrega del balón. Mide la fiabilidad del jugador para mantener la posesión.
6. **Intercepciones P90 (Lectura Defensiva)**: Tasa estandarizada de cortes de balón mediante anticipación geométrica posicional.
7. **% Duelos Aéreos (Dominancia Física por Alto)**: Porcentaje de disputas por arriba ganadas sobre el total de duelos aéreos protagonizados.
8. **Recuperaciones P90 (Intensidad de Recolección)**: Frecuencia por partido con la que el jugador toma posesión de balones sueltos o desatendidos en el campo.
9. **Influencia Global P90 (Volumen de Participación)**: Conteo total de todas las acciones y eventos registrados por el jugador en el partido. Distingue a los directores de juego de alto volumen de aquellos jugadores periféricos o aislados.
10. **Faltas Recibidas P90 (Atracción de Gravedad)**: Capacidad para desequilibrar y obligar al rival a cometer infracciones físicas para detener su avance.

2.4 Fase 4: Normalización y Validación de Ortogonalidad

Para evitar un problema clásico de los modelos basados en distancias (donde una variable con magnitudes grandes como la *Influencia Global P90*, que supera las 150 unidades, aplasta por completo a una variable de escala pequeña como el *xG P90*, que se mueve entre 0 y 1), aplicamos una **Normalización Min-Max**. Esta transformación matemática escala todas las métricas estrictamente al intervalo cerrado $[0, 1]$ mediante la fórmula:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min} + 1e - 8} \quad (1)$$

Previo al modelado, calculamos la matriz de correlación lineal de Pearson sobre los datos normalizados. El análisis visual de esta matriz validó que las 10 métricas seleccionadas introdujeran dimensiones de información diferenciadas y no redundantes, garantizando que problemas de hiper-colinealidad no distorsionen las fuerzas vectoriales que organizarán el mapa neuronal.




Figura 1: Matriz de Correlación de las 10 variables tácticas normalizadas P90. Las bajas correlaciones cruzadas validan empíricamente la ortogonalidad del espacio multidimensional.

3. FUNDAMENTOS DE LOS MAPAS AUTOORGANIZADOS (SOM)

Visualizar y entender una matriz de datos con 10 dimensiones es imposible para el ojo humano, ya que nuestro cerebro solo procesa hasta tres dimensiones físicas. Un Mapa Autoorganizado (SOM, por sus siglas en inglés o Redes de Kohonen) es una arquitectura de red neuronal artificial diseñada para resolver esta limitación.

Su función principal es tomar ese espacio hiperdimensional de 10 variables y proyectarlo en una grilla plana bidimensional (por lo general, una matriz rectangular de casillas o neuronas). El SOM opera bajo el principio de **aprendizaje competitivo no supervisado**, lo que significa que no requiere de etiquetas preestablecidas o “respuestas correctas”; la red descubre la estructura interna de los datos por sí sola.

Durante el entrenamiento, cada casilla de la grilla (neurona) mantiene un vector de pesos de 10 dimensiones, intentando imitar los perfiles reales de los jugadores. Cuando un jugador es introducido al algoritmo, todas las casillas compiten: se calcula la distancia euclidiana entre los números del jugador y los pesos de cada neurona. La casilla que guarde la distancia más corta es proclamada la **BMU** (*Best Matching Unit* o Unidad de Mejor Ajuste).

El mapa se organiza mediante un mecanismo de arrastre coordinado: la BMU ganadora ajusta sus pesos para parecerse aún más al jugador, y tracciona consigo a sus casillas vecinas en la grilla. Al finalizar este proceso masivo de iteración, el mapa se ordena geográficamente solo: los jugadores con perfiles conductuales similares son atraídos hacia las mismas coordenadas del tablero, mientras que los perfiles opuestos quedan segregados en esquinas contrarias.

3.1 El Conflicto Matemático: Error de Cuantificación vs. Error Topológico

Para evaluar la calidad analítica y el nivel de deformación de nuestro mapa, calculamos simultáneamente dos métricas de error que compiten directamente en un equilibrio de fuerzas:

- **Error de Cuantificación (QE):** Mide la precisión del dibujo numérico. Es la distancia promedio entre los datos de los jugadores reales y los pesos de la casilla donde fueron asignados. Un QE bajo indica que las casillas describen fielmente las estadísticas individuales de sus huéspedes.
- **Error Topológico (TE):** Mide la coherencia de la vecindad geométrica. El principio básico de cualquier mapa confiable es que si la casilla A está al lado de la casilla B, los perfiles que habitan en ellas deben ser muy parecidos. Técnicamente, el TE calcula el porcentaje de jugadores cuya segunda mejor casilla de ajuste no es vecina directa de su BMU principal.

Cuando una red SOM se configura de manera incorrecta (por ejemplo, utilizando una tasa de aprendizaje exageradamente agresiva o un radio de vecindad inicial muy cerrado), la red sufre un fenómeno crítico conocido como “**desgarro topológico**”. Esto significa que la red se enfoca tanto en clavar la precisión numérica individual (bajando el QE de forma artificial) que termina arrugando y fracturando la continuidad dimensional del mapa. Como resultado, podrías tener a un delantero centro goleador ubicado en una casilla contigua a la de un defensa central rústico. El mapa pierde toda su coherencia lógica y visual, volviéndose inútil para la toma de decisiones tácticas.

4. OPTIMIZACIÓN EVOLUTIVA MEDIANTE ALGORITMO GENÉTICO (AG)

Para inicializar un SOM, el analista debe definir cuatro hiperparámetros fundamentales: el número de filas de la grilla, el número de columnas, el radio de vecindad inicial (σ_0) que controla la fuerza de arrastre sobre las casillas contiguas, y la tasa de aprendizaje inicial (α_0) que regula la velocidad de ajuste. Tradicionalmente, estos valores se eligen “al ojo” o mediante cuadrículas de prueba y error (*Grid Search*), lo cual es ineficiente y propenso a generar mapas con desgarros.

Para eliminar la subjetividad humana, delegamos esta sintonización en un **Algoritmo Genético (AG)**. El AG es una técnica metaheurística de búsqueda profunda inspirada en los principios de la selección natural y la evolución darwiniana. La mecánica del motor evolutivo opera de la siguiente manera:

1. **Población y Cromosomas:** El algoritmo inicializa de forma aleatoria una población de 30 individuos o “cromosomas”. Cada cromosoma codifica en sus genes una combinación única de los cuatro hiperparámetros requeridos: [Filas, Columnas, σ_0 , α_0].
2. **Función de Aptitud (Fitness Multiobjetivo Constreñido):** Cada cromosoma configura un modelo SOM temporal y ejecuta un entrenamiento rápido y acelerado (3.000 iteraciones) para evaluar su viabilidad matemática. Para blindar al mapa contra las fracturas de red, diseñamos una función de aptitud combinada: le asignamos un peso del 40 % al Error de Cuantificación y un peso mayor del 60 % al Error Topológico. Adicionalmente, se introduce una penalización matemática severa para aquellas configuraciones cuyas dimensiones de grilla generen un volumen total de neuronas que se desvíe de la regla heurística estándar ($M \approx 5\sqrt{N}$).
3. **Operadores de Selección y Cruce:** Las configuraciones que minimizan el error combinado tienen una mayor probabilidad de ser seleccionadas mediante torneos de baja presión selectiva ($k = 2$). Esto protege la diversidad genética permitiendo que genes potencialmente valiosos de modelos subóptimos no sean eliminados de inmediato. Los cromosomas ganadores se emparejan e intercambian sus segmentos genéticos mediante un mecanismo de cruce uniforme, procreando una nueva generación de modelos.
4. **Mutación y Mecanismo de Cataclismo:** Para evitar la homogeneidad de las soluciones y el estancamiento en óptimos locales falsos, se aplican mutaciones con una probabilidad drástica del 40 %,

alternando entre micro-ajustes gaussianos finos para las tasas de aprendizaje y macro-mutaciones aleatorias para las dimensiones estructurales. Si el motor detecta un estancamiento absoluto en la aptitud de la población durante tres generaciones consecutivas, activa una **Sustitución Cataclísmica**: ejecuta una purga masiva del 50 % inferior de la población, reemplazándola instantáneamente por configuraciones “alienígenas” 100 % nuevas para forzar la exploración de zonas inexploradas del espacio paramétrico.

Al concluir las 50 generaciones del ciclo evolutivo, el algoritmo capturó e inyectó los hiperparámetros ganadores definitivos: una grilla rectangular estable de 11×19 (170 neuronas), un radio inicial expansivo $\sigma_0 = 8,85$ y una tasa de aprendizaje calibrada en $\alpha_0 = 0,075$.

Console Output: Hitos de Convergencia del AG

Iniciando AG de Exploración Profunda — Target: 179 neuronas
 [Gen 01] Fitness: 0.0696 — Malla: 16x11 — Sigma: 7.34 — LR: 0.090
 [Gen 04] Fitness: 0.0597 — Malla: 12x17 — Sigma: 7.34 — LR: 0.090
Estancamiento detectado. Activando purgas cataclísmicas.
 [Gen 26] Fitness: 0.0591 — Malla: 11x19 — Sigma: 8.85 — LR: 0.080
 [Gen 50] Convergencia estable. Elitismo retiene mejor histórico.

BÚSQUEDA FINALIZADA. MEJORES HIPERPARÁMETROS:

Grilla : 11x19 / Sigma : 8.85 / LR : 0.075

5. AUDITORÍA COMPARATIVA Y ENTRENAMIENTO

El valor real del modelado no es predecir, sino validar metodológicamente la arquitectura. Esta fase instanció un entrenamiento profundo competitivo, alimentando la misma data tanto a un modelo de control (empírico) como al modelo optimizado por nuestro Algoritmo Genético (AG).

5.1 Resultados del Experimento

Los resultados arrojan conclusiones definitivas sobre la superioridad del modelo evolutivo.

Cuadro 1: Resultados de la Auditoría Estadística de los Modelos SOM

Métrica	Modelo Control	Modelo Optimizado (AG)	Variación
Error de Cuantificación (QE)	0.0667	0.0645	-3.35 %
Error Topológico (TE)	0.1584	0.0668	-57.84 %

La intervención del motor evolutivo proveyó una superioridad estadística absoluta. A diferencia de las configuraciones empíricas, el AG no solo mejoró la precisión del ajuste individual (reduciendo el QE en un 3.35 %), sino que al forzar un radio inicial expansivo ($\sigma_0 = 8,85$), garantizó un despliegue armónico de la malla. La monumental mejora del **57.84 % en la coherencia espacial (TE)** es la prueba matemática definitiva de que el mapa carece de fracturas topológicas, superando al modelo de control en todas las dimensiones de evaluación.

5.2 Visualización de Auditoría

En las Figuras se observa el diagnóstico final del experimento. Mientras que la U-Matrix revela la estructura de los clústeres mediante transiciones topográficas, los Planos de Componentes permiten interpretar qué variables tácticas dominan en cada región del mapa, validando la coherencia del motor evolutivo.




Figura 2: Visualización del espacio latente: Coherencia estructural y distribución de variables tácticas.

6. INTERPRETACIÓN DE LOS CLÚSTERES TÁCTICOS

Tras estabilizar la red, aplicamos un clustering mediante *K-Means* sobre los pesos suavizados.

6.1 Selección del Número de Clústeres (k)

Para evitar la subjetividad, utilizamos heurísticas objetivas. El **Método del Codo** identifica el punto donde la inercia disminuye marginalmente, y el **Score de Silueta** evalúa la cohesión y separación de los grupos. El análisis de estas métricas reveló que matemáticamente era viable segmentar la población en 4, 12 o incluso 19 clústeres. No obstante, la decisión final de establecer $k = 12$ responde a un estricto criterio de equilibrio analítico: configurar el modelo en 4 clústeres habría agrupado perfiles tácticos de manera demasiado general, ocultando matices valiosos; por el contrario, extenderlo a 19 grupos habría fragmentado la información en exceso, dificultando su interpretación práctica en el *scouting*. Por lo tanto, 12 arquetipos ofrecen la granularidad exacta para identificar comportamientos únicos y accionables sin perder el foco narrativo.




Figura 3: Método del Codo y de la silueta

6.2 Perfilado de los 12 Arquetipos

Tras la optimización y el proceso de clustering, la red neuronal ha segmentado la élite futbolística en 12 arquetipos tácticos, organizados en cinco familias narrativas según sus ejes de comportamiento:

1. Eje Creativo y de Desequilibrio

- **C11 (Maestros y Desequilibrantes):** El arquetipo de élite. Dominan la Influencia Global, Asistencias a Tiro y generan el mayor volumen de faltas recibidas del torneo.
- **C5 (Asistidores de Complemento):** Perfil de soporte que mantiene una alta capacidad creativa y resistencia a la presión, actuando como conectores de juego con mayor despliegue lateral.

2. Evolución del Ataque

- **C8 (Atacantes Totales):** El perfil más completo; dominan el xG P90 y participan activamente en el juego asociativo bajo presión.
- **C2 (Finalizadores y Amenazas Ofensivas):** Especialistas en eficacia pura. Alto xG por tiro; incluyen tanto a delanteros letales como a centrales especialistas en el remate a balón parado.
- **C1 (Fijadores de Marca):** Especialistas en retención. Su rol es recibir de espaldas y descargar bajo presión, con una capacidad superior para mantener el balón en campo rival.
- **C10 (Delanteros Aislados):** Perfil de baja influencia; su participación se limita a retención forzada con poco volumen de creación o remate.

3. Muralla y Salida de Balón

- **C7 (Constructores desde el Fondo):** Defensores con fiabilidad técnica superior; líderes indiscutidos en porcentaje de pases exitosos y control del ritmo.
- **C3 (Especialistas en Anticipación):** Defensores tácticos; su especialidad es la lectura del juego, liderando en intercepciones y distribución limpia.

4. Sala de Máquinas

- **C9 (Motores Box-to-Box):** Jugadores de cobertura total; dominan el juego aéreo, la distribución y la imposición física en todo el campo.
- **C0 (Pivotes de Contención):** Destruidores posicionales. Máxima eficiencia en la recuperación de balones sueltos a ras de suelo.
- **C6 (Híbridos de Complemento):** Jugadores de equilibrio que mantienen la estructura táctica sin asumir riesgos, dando continuidad al sistema con pases seguros.

5. Grupo Periférico

- **C4 (Soportes Periféricos):** Perfil con métricas de participación ínfimas. Incluye a guardametas y jugadores de campo desconectados del flujo táctico principal.




Figura 4: Mapa de neuronas segmentado por los 12 clústeres identificados.

7. CONCLUSIONES FINALES

El desarrollo de este trabajo permite extraer tres conclusiones fundamentales sobre el uso de la Inteligencia Artificial en el análisis deportivo:

1. **Necesidad de la Optimización Heurística:** La sintonización empírica de los Mapas Autoorganizados es insuficiente para datos de alta dimensionalidad. La implementación de Algoritmos Genéticos es un requisito metodológico obligatorio para garantizar la estabilidad geométrica y eliminar sesgos humanos en la calibración del modelo.
2. **Prioridad de la Coherencia Espacial:** El éxito de un modelo SOM no reside exclusivamente en la precisión numérica (QE), sino en la coherencia topológica (TE). Optimizar la selección de hiperparámetros para ganar más de un 50% de coherencia espacial es la clave para que el mapa sea interpretable y científicamente válido.
3. **Potencial de la Segmentación Automatizada:** La capacidad de generar 12 arquetipos tácticos a partir de datos crudos demuestra que el *scouting* automatizado es una realidad técnica. Este pipeline proporciona una base científica sólida para la toma de decisiones estratégicas, permitiendo a los equipos identificar perfiles de rendimiento con precisión absoluta.

7.1 Limitaciones y Trabajo Futuro

Es importante destacar que el foco central de esta investigación fue la **optimización metodológica de la arquitectura SOM** mediante motores evolutivos, y no la descripción exhaustiva de los perfiles resultantes. Por tanto, el análisis presentado de los 12 clústeres es de carácter ilustrativo para validar el poder de la técnica. Como trabajo futuro, se propone una inmersión analítica profunda en la caracterización individual de cada uno de los 12 arquetipos tácticos identificados, trascendiendo la mera descripción estadística para decodificar el comportamiento real de los jugadores.

Este enfoque orientado a la aplicación permitirá transformar el modelo en una herramienta de soporte a la toma de decisiones para ojeadores y cuerpos técnicos, desplazando la subjetividad del análisis visual convencional o el "ojo clínico" hacia un paradigma de decisión basado en evidencia estadística. En

este contexto, el sistema permitirá identificar talentos emergentes ("joyas ocultas"), detectando alternativas con bajo perfil mediático cuyo rendimiento estadístico iguale o supere a jugadores de renombre, optimizando así la gestión de activos en el mercado de fichajes. Finalmente, se integrará la validación cruzada con expertos tácticos y la incorporación de variables biométricas para refinar la taxonomía de los jugadores y dotar al sistema de una capacidad predictiva superior.